

基于 SSA-LSTM 模型的流域水质分析及预测

褚林峰¹ 何延新¹ 党艳¹ 王林¹ 孙杰娟¹ 常坤^{2*} 王振强² 田高峰²

(1 西安市生态环境局, 陕西 西安 710016; 2 力合科技(湖南)股份有限公司, 湖南 长沙 410205)

摘要 水质动态预测是流域综合治理与生态修复的关键科学支撑。本研究以渭河干流关中段为研究区, 基于2021—2023年7个国控监测断面的多源实时监测数据, 综合运用水质指数法(WQI)、Pearson相关性分析及神经网络模型, 开展水质时空特征解析与溶解氧(DO)高精度预测研究。结果表明: 研究期内流域WQI值为60~90, 水质优良率达97.4%, 整体稳定; 上游水质优于中下游, 春秋季水质较优、夏季较差, 氨氮(NH₃-N)和总磷(TP)为主要波动污染因子。通过Pearson相关性分析筛选出水温、电导率、pH值、浊度、总磷、总氮(TN)与DO强相关的指标作为模型输入因子, 有效降低数据冗余。对比LSTM、GRU及SSA-LSTM模型, 传统LSTM存在过拟合, GRU精度有待优化, SSA-LSTM模型表现最优, 其训练集与测试集的均方根误差(RMSE)分别低至0.34 mg·L⁻¹和0.39 mg·L⁻¹, 决定系数(R²)均接近0.95, 可精准捕捉DO波动特征, 波峰波谷区域拟合效果显著优于其他模型。本研究明确了渭河关中段水质时空演变规律及驱动机制, 验证了SSA-LSTM模型在水质高精度预测中的优越性, 可为渭河及黄河流域的水质管理决策、污染精准管控及水生态保护提供科学依据。

关键词 水质综合评价; 时空特征; 神经网络; 水质预测; 模型性能

中图分类号: X824 **文献标识码:** A **文章编号:** 1673-3290(2026)02-0002-08

Watershed Water Quality Analysis and Prediction Based on SSA-LSTM Model

CHU Lin-feng¹ HE Yan-xin¹ DANG Yan¹ WANG Lin¹ SUN Jie-juan¹ CHANG Kun^{2*}

WANG Zhen-qiang² TIAN Gao-feng²

(1 Xi'an Ecological Environment Bureau, Xi'an 710016, Shaanxi, China; 2 Lihe Technology (Hunan) Co., Ltd., Changsha 410205, Hunan, China)

Abstract Dynamic prediction of water quality is a key scientific support for integrated watershed management and ecological restoration. Taking the Guanzhong section of the mainstream of the Weihe River as the study area, this study used multisource real-time monitoring data from seven national control monitoring sections during 2021–2023, and by comprehensively applying the Water Quality Index (WQI), Pearson correlation analysis and neural network models, the spatiotemporal characteristics of water quality and high-precision prediction of dissolved oxygen (DO) were investigated. The results indicated that during the study period, the WQI values of the watershed ranged from 60 to 90, with the proportions of excellent and good water quality grades reaching 97.4%, indicating an overall stable water quality. Spatially, the water quality was better in the upstream than that in the middle and downstream, and temporally, the water quality was better in spring and autumn but poorer in summer, with ammonia nitrogen (NH₃-N) and total phosphorus (TP) being the main fluctuating pollution factors. Six indicators strongly correlated with DO, including water temperature, electrical conductivity, pH, turbidity, TP and total nitrogen (TN), were screened out by Pearson correlation analysis as the input factors of the model, which effectively reduced data redundancy. By comparing the LSTM, GRU and SSA-LSTM models, it was found that the traditional LSTM model had the problem of overfitting the prediction accuracy of the GRU model needed to be optimized, while the SSA-LSTM model performed the best; its root mean square error (RMSE) of the training set and test set was as low as 0.34 mg·L⁻¹ and 0.39 mg·L⁻¹ respectively, and the coefficients of determination (R²) was close to 0.95 in both sets. This model can accurately capture the fluctuations characteristics of DO, and its fitting effect in the peak and trough areas is significantly better than that of other models. This study clarifies the spatiotemporal evolution patterns and driving mechanisms of water quality in the Guanzhong section of the Weihe River, verifies the superiority of the SSA-LSTM model in high-precision water quality prediction, and provides a scientific basis for water quality management decisions, targeted pollution control and aquatic ecosystem protection in the Weihe River and Yellow River Basin.

Key words Comprehensive water quality evaluation; Spatiotemporal characteristics; Neural network; Water quality prediction; Model performance

收稿日期: 2025-12-01

作者简介: 褚林峰, 主要研究方向: 水环境保护及污染治理。E-mail: 178294626@qq.com

* 通讯作者: 常坤, 主要研究方向: 水环境监测与治理。E-mail: 847058915@qq.com

水资源是生态稳定与社会经济可持续发展的核心。我国水生态环境保护成效显著，但地表水环境质量改善存在区域间不平衡问题（李振涵等，2024；Han et al., 2024）。精确分析与预测水质和水环境质量，是维护水环境安全、实现水资源科学开发与保护的关键（Tian et al., 2024；刘怡等，2023）。

水质评价旨在通过定性与定量方法揭示污染物迁移转化规律及时空分异特征，常用单因子评价法、人工神经网络法、水质综合指数法（WQI）及模糊数学法（郑立地等，2025；孙天一等，2024）。其中，WQI 通过整合溶解氧（DO）、氨氮（ $\text{NH}_3\text{-N}$ ）等关键指标并赋予权重，生成综合评分，可显著增强对水环境时空格局的解析能力。研究表明，WQI 结合多元统计分析能有效识别水体在旱雨两季的空间异质性及氮磷等主要污染源（陈慧等，2025），与地理探测器等空间分析工具联用，能进一步揭示河流水质改善的阶段性特征及丰水期面源污染贡献（夏诗语等，2025）。

水质预测分为物理驱动（机理）和数据驱动（非机理）两类模型。物理驱动模型数据质量要求高、计算复杂且外推能力有限（石晴宜等，2021），而 LSTM 和 GRU 等数据驱动模型因适配长序列数据特性更具优势（Bibi et al., 2025；郭燕等，2021）。现有研究通过构建 CNN-GRU 混合模型（苏辉锋等，2023）或结合经验动态建模（EDM）等方法（白冰等，2024）提升预测精度，但水环境系统复杂性及数据非线性和波动特征仍带来预测瓶颈。麻雀搜索算法（SSA）可提升模型鲁棒性注（何勇等，2024），但目前研究多注重于单一的数据序列分解或参数初值优化，缺乏综合性的改进策略。渭河（关中段）作为黄河最大支流，流经关中平原核心经济带，其水环境质量关乎区域生态安全与黄河流域高质量发展，优化模型以克服数据波动、实现高精度水质趋势预测是当前研究的难点与重点。本研究以渭河（关中段）为对象，采用 WQI 法解析水质时空演变规律，聚焦溶解氧开展预测。以 LSTM 与 GRU 作为模型构件的核心算法，引入 SSA 优化 LSTM 模型参数以克服过拟合、提高预测能力。通过均方根误差（RMSE）、平均绝对误差（MAE）与决定系数（ R^2 ）3 项指标对比 3 种模型的 DO 预测效果，为渭河乃至黄河流域水污染控制与政策制定提供科学支撑。

1 材料与方法

1.1 研究区概况

渭河流域跨甘肃、宁夏、陕西 3 省，总流域面积 13.48 万 km^2 ，其中陕西境内干流长 502 km，流域面积 7.25 万 km^2 （图 1）。地势西高东低，南倚秦岭，北靠渭北北山，中部为冲积—洪积平原，地貌涵盖山地、黄土台塬、丘陵及平原，以黄绵土、褐土为主，侵蚀敏感性与渗透性差异显著。该流域属暖温带大陆性季风气候，年均气温 7.8~13.5℃，年均降水约 550 mm，时空分布不均且呈“南多北少”特征。受降水集中、蒸发强烈、泥沙输移剧烈及土地利用交错影响，流域形成“水量季节悬殊、污染过程脉冲式、水质空间差异显著”的水环境特征。




图 1 研究区示意图
Fig.1 Study area diagram

1.2 数据来源及预处理

选取陕西境内魏家堡、卧龙寺桥等 7 个国控水质监测断面为研究对象，覆盖渭河（关中段）干流（图 1），数据来源于西安市生态环境局，采集时间 2021—2023 年，每 4 h 监测 1 次，包含水温、pH 值、电导率、溶解氧、总磷（TP）、总氮（TN）、氨氮、高锰酸盐指数（ COD_{Mn} ）和浊度 9 项水质指标。对数据进行异常值剔除、缺失值插值补全及归一化处理，消除量纲差异；按 8:2 比例划分为训练集（构建网络优化模型）和测试集（检验拟合效果），该比例参考相关研究经验并结合实际数据情况确定（Nallakaruppan et al., 2024；Pang et al., 2024）。

1.3 研究方法

1.3.1 水质指数评价法 WQI 是水质综合评价指标，通过加权整合多个水质参数，反映水质时空变化特征并识别关键污染因子，基于代表性污染因子，结合各水体功能区标准归一化处理后计算综合系数，反映水质状况。计算公式如下：

$$WQI = \frac{\sum_{i=1}^n C_i P_i}{\sum_{i=1}^n P_i}$$

式中： n 为水质指标个数， P_i 为第 i 个指标的权重， C_i 为第 i 个指标的标准化值。

各参数权重及归一化值见表 1， C_i 阈值依据

GB3838—2002《地表水环境质量标准》划分， P_i 取值范围为 3~4（唐琦等，2022；Pesce et al., 2000）。

WQI 为无量纲数，数值越大表示综合水质越好，分为优秀（80~100）、良好（60~80）、中等（40~60）、差（20~40）、非常差（0~20）5 个等级。

表 1 水质指标权重及归一化值
Table 1 Water quality index weight and normalized value

水质指标	权重 (P_i)	归一化值 (C_i)					
		100	80	60	40	20	0
DO/(mg·L ⁻¹)	4	[7.5, +∞)	[6.0, 7.5)	[5.0, 6.0)	[3.0, 5.0)	[2.0, 3.0)	[0, 2.0)
COD _{Mn} /(mg·L ⁻¹)	3	[0, 2.0]	(2.0, 4.0]	(4.0, 6.0]	(6.0, 10.0]	(10.0, 15.0]	(15.0, +∞)
NH ₃ -N/(mg·L ⁻¹)	3	[0, 0.15]	(0.15, 0.5]	(0.5, 1.0]	(1.0, 1.5]	(1.5, 2.0]	(2.0, +∞)
TP/(mg·L ⁻¹)	4	[0, 0.02]	(0.02, 0.1]	(0.1, 0.2]	(0.2, 0.3]	(0.3, 0.4]	(0.4, +∞)

1.3.2 构建水质预测模型

1) 长短时记忆神经网络。LSTM 是循环神经网络 (RNN) 的扩展模型，专用于处理时序数据，通过存储单元和遗忘门、输入门、输出门 3 个门控结构保存信息并处理长序列。其采用结构化门控制存储单元的信息增减，其中遗忘门由 sigmoid 函数控制，输出 1 信息保留，0 遗忘信息。根据当前和以前的状态执行，其前向计算公式如下：

$$\begin{aligned} i_t &= \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \\ f_t &= \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \\ c_t &= f_t c_{t-1} + i_t \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \\ o_t &= \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o) \\ h_t &= o_t \tanh(c_t) \end{aligned}$$

式中： i 为输入门； f 为遗忘门； c 为细胞状态； o 为输出门； W 为对应的权重系数矩阵； b 为对应的偏置项； σ 为 sigmoid 激活函数； $\tanh$ 为双曲正切激活函数。

2) 门控神经网络。GRU 是 LSTM 的优化变体，仅含重置门和更新门，保留其解决梯度消失的优势，同时缩减门控结构参数，提升训练效率（杨坪宏等，2023）。数学公式如下：

$$\begin{aligned} z_t &= \sigma(W_z x_t + U_z h_{t-1}) \\ r_t &= \sigma(W_r x_t + U_r h_{t-1}) \\ \tilde{h}_t &= \tanh(r_t \cdot U_h h_{t-1} + W_h x_t) \\ h_t &= (1 - z_t) \cdot \tilde{h}_t + z_t \cdot h_{t-1} \end{aligned}$$

式中： z_t 、 r_t 分别为 t 时刻更新门输出、重置门输出， x_t 为 t 时刻的输入变量， h_t 、 h_{t-1} 分别为当前隐藏层输出、上一时刻隐藏层输出， $\tilde{h}_t$ 为 x_t 与 h_{t-1} 的汇总形式， σ 为 sigmoid 激活函数， W_z 、 W_r 、 W 、 U_z 、 U_r 、 U 为权重矩阵（其中： W_r 与 U_r 为重置门的权重

矩阵， W_z 与 U_z 为更新门的权重矩阵， W 与 U 为临时输出的权重矩阵）。

3) 麻雀搜索算法。麻雀搜索算法 (SSA) 是群体智能优化算法，运行过程为：初始化种群生成初始解，计算个体适应度值，按适应度值划分发现者和追随者并更新位置，通过反捕食机制增强跳出局部最优能力，重复上述步骤直至目标函数值趋于稳定，满足停止条件。

1.3.3 输入因子集选择 采用 Pearson 相关系数法筛选与 DO 相关性较强的数据，以提高神经网络预测精度，变量关联紧密程度依据相关系数范围判定（表 2）。需注意，Pearson 相关系数仅度量线性依赖关系（ $|r|$ 趋近 1 则线性关联强，趋近 0 则微弱），但当 $|r|$ 趋近 0 不等同于“无关联”，可能存在未被捕捉的非线性关联。Pearson 相关系数如下：

$$r = \frac{\text{cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n-1} \sum (x_i - \bar{x})^2} \sqrt{\frac{1}{n-1} \sum (y_i - \bar{y})^2}}$$

式中： x 和 y 为需判断相关性的变量， x_i 和 y_i 为样本均值。

表 2 相关程度判别表
Table 2 Correlation degree discriminant table

相关系数 绝对值	相关程度	相关系数 绝对值	相关程度
0.0~0.2	极弱相关或无相关	0.6~0.8	强相关
0.2~0.4	弱相关	0.8~1.0	极强相关
0.4~0.6	中等相关	—	—

1.3.4 模型性能评价指标 本研究选择均方根误差 (RMSE)、平均绝对误差 (MAE) 和决定系数 (R^2) 作为判断模型预测效果的基础。计算公式如下：

$$\begin{aligned} \text{RMSE} &= \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \\ \text{MAE} &= \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \end{aligned}$$

$$R^2=1-\frac{\sum_{i=1}^n (y_i-\hat{y}_i)^2}{\sum_{i=1}^n (y_i-\bar{y})^2}$$

式中： n 为数据数量； y_i 为模型预测值； y_i 为测试集的值。

2 结果与分析

2.1 水质特征及时空评价

2.1.1 水质特征 如表 3 所示，DO 平均值为 $9.35\pm 1.77\text{ mg}\cdot\text{L}^{-1}$ ，高于地表水 I 类标准 ($7.50\text{ mg}\cdot\text{L}^{-1}$)，最低值为 $5.49\text{ mg}\cdot\text{L}^{-1}$ ，所有监测值均不低于 III 类标准；标准差和变异系数分别为 1.77 和 0.19，表明 DO 浓度波动较小，整体稳定。COD_{Mn} 平均值 $3.56\pm 1.31\text{ mg}\cdot\text{L}^{-1}$ （达标），最大值达 $10.56\text{ mg}\cdot\text{L}^{-1}$ （超标 75%），最小值 $1.31\text{ mg}\cdot\text{L}^{-1}$ （优），表明个别站点存在严重的有机污染，需开展污染源排查。NH₃-N 及 TP 波动性较大，高值站点污染主要受生活污水排放及农业面源污染影响。

表 3 水质基本参数汇总

Table 3 Summary of basic water quality parameters

水质参数	平均值 ± 标准差 /($\text{mg}\cdot\text{L}^{-1}$)	最小值 / ($\text{mg}\cdot\text{L}^{-1}$)	最大值 / ($\text{mg}\cdot\text{L}^{-1}$)	变异系数
DO	9.35 ± 1.77	5.49	16.06	0.19
COD _{Mn}	3.56 ± 1.31	1.31	10.56	0.37
NH ₃ -N	0.23 ± 0.26	0.02	2.39	1.16
TP	0.10 ± 0.07	0.02	0.79	0.71

2.1.2 水质时间特征评价 基于 WQI 评价结果，各监测断面 WQI 值为 60~90，整体处于良好和优秀等级（图 2）。其中，优秀占 52.7%，良好占 44.7%，中等和差合计仅占 2.6%，表明该流域水质较好且稳定。年际变化上，卧龙寺桥和兴平监测断面 WQI 值最稳定，水质最好；咸阳铁桥出现 WQI 值低于 40 的月份，但随后逐渐回升，说明短期间存在污染并得到及时治理。季节变化方面，流域水质




图 2 水质时间变化
Fig.2 Time variation of water quality

表现为春、秋季较好，夏季最差。

2.1.3 水质空间特征评价 基于 2021—2023 年 WQI 均值分析，各监测断面总体水质均达良好及以上水平（图 3）。上游水质较好、中下游较差。从水质评价等级分布来看，中上游水质多为“优秀”等级；自咸阳铁桥断面起，“良好”等级占主要部分，并短暂出现等级为差的情况。

2.2 水质预测分析

2.2.1 输入因子集选择 由于实时监测数据受噪声干扰，为确保模型预测精度，需分析 DO 与其他指标的相关性筛选有效输入因子集（李海华等，2024）。基于监测断面 2021—2023 年实时水质数据，对 DO 与水温、电导率、pH 值、浊度、TP、TN、NH₃-N 进行 Pearson 相关性分析（图 4）。结果表明，DO 与水温、电导率、pH 值、TN 呈极强相关 ($|r|>0.8$)，与浊度呈中等相关 ($0.4\leq |r|<0.5$)，与 TP 呈弱相关 ($0.2\leq |r|<0.3$)，与 NH₃-N 呈极弱相关 ($|r|<0.2$)。依据 $|r|\geq 0.2$ 的阈值，剔除 NH₃-N，选择其余 6 项指标作为输入因子，DO 为输出项构建预测模型，可减少数据冗余，提升模型适用性与预测可信度。




图 3 水质空间变化
Fig.3 Spatial variation of water quality




图4 水质指标 Pearson 相关性热图

Fig. 4 Pearson correlation heatmap of water quality index

2.2.2 溶解氧预测结果分析 本研究对比 LSTM、GRU 和 SSA-LSTM 模型对 DO 的预测效果 (图 5)，并评估人工神经网络模型在水质预测中的性能 (图 6)。结果显示，3 种模型整体预测趋势与实测值基本一致，均具备水质动态预测能力，但存在细节波动误差。其中，LSTM 模型训期拟合较好，测试期误差较大，在实际值波动区域偏差明显。GRU 模型预测精度优于 LSTM，能捕捉真实值波动特征，但对波峰、波谷预测仍有不足。SSA-LSTM 模型训练期及测试期拟合效果均优于前两个模型， R^2 更高，在数据波动区模拟效果更好，预测精度显著提升，验证了算法改进的有效性。研究表明，人工神经网络




图5 3种神经网络预测结果

Fig. 5 Prediction results of three neural networks

注：图 (a)、(b)、(c) 分别为 LSTM、GRU、SSA-LSTM 模型训练集与测试集的预测结果。

Note: Figure (a), (b) and (c) show the prediction results of the training and test sets for LSTM, GRU and SSA-LSTM models, respectively.




图6 3种神经网络预测性能对比

Fig.6 Comparison of prediction performance of three neural networks

注：图(a)、(b)、(c)分别为LSTM、GRU、SSA-LSTM模型训练集与测试集的预测性能。

Note: Figure (a), (b) and (c) show the prediction performance of the training and test sets for LSTM, GRU and SSA-LSTM models, respectively.

络可通过多层非线性函数映射建立输入参数与DO的高精度关联，其中SSA-LSTM凭借参数优化机制，强化了模型的泛化能力与鲁棒性，为水质实时监测提供了可靠预测工具。

2.2.3 模型评价结果的对比分析

为评估人工

神经网络模型对DO的预测性能，本研究对比了LSTM、SSA-LSTM和GRU模型的拟合效果与泛化能力。由表4可知，传统LSTM训练集RMSE和MAE分别为 $0.80 \text{ mg} \cdot \text{L}^{-1}$ 和 $0.53 \text{ mg} \cdot \text{L}^{-1}$ ($R^2=0.92$)，测试集误差显著升高 ($\text{RMSE}=1.30 \text{ mg} \cdot \text{L}^{-1}$ 、

表 4 3 种神经网络评价结果对比
Table 4 Comparison of evaluation results of three neural networks

模型	MAE		RMSE		R ²	
	训练集	测试集	训练集	测试集	训练集	测试集
LSTM	0.53	0.93	0.80	1.30	0.92	0.73
GRU	0.45	0.65	0.70	0.92	0.91	0.81
SSA-LSTM	0.66	0.60	0.34	0.39	0.93	0.94

MAE=0.93 mg·L⁻¹, R²=0.73), 存在过拟合; GRU 模型精度优于 LSTM (训练集 RMSE=0.70 mg·L⁻¹、MAE=0.45 mg·L⁻¹, R²=0.91; 测试集 RMSE=0.92 mg·L⁻¹、MAE=0.65 mg·L⁻¹, R²=0.81), 但仍低于 SSA-LSTM 模型。SSA 法优化后的 LSTM 模型表现最佳, 训练集 RMSE 和 MAE 分别为 0.34 mg·L⁻¹ 和 0.66 mg·L⁻¹ (R²=0.93), 测试集上 RMSE 和 MAE 分别为 0.39 mg·L⁻¹ 和 0.60 mg·L⁻¹ (R²=0.94), 误差降低且 R² 最接近 1, 其参数与网络结构优化有效提升了模型稳定性与预测精度。结合图 5 与表 4, SSA-LSTM 在波峰波谷处的预测趋势与真实值高度一致, 验证其在复杂水质波动场景的优越性, 为 DO 动态预测提供更可靠方案。

3 讨论

3.1 水质变化特征驱动机制解析

2021—2023 年渭河 (关中段) 水质整体为优秀 - 良好等级 (占比 97.4%), WQI 值稳定在 60~90, 契合区域水环境治理成效。水质呈“春秋优、夏季差”特征, 核心驱动为气候与人类活动协同作用。夏季高温加剧水体微生物代谢, 有机污染物释放量增加 (孙迎迎等, 2025; 左韧等, 2024), 汛期径流携带农业面源污染物和城市地表污染物汇入河道, 并扰动底泥二次释放污染物, 导致水质下降 (罗清月等, 2025)。年际间, 卧龙寺桥、兴平断面 WQI 值持续稳定, 而咸阳铁桥出现短期水质恶化后快速回升, 印证应急处置机制有效但存在突发性污染风险。上游水质优于中下游, 本质是自然地理条件与人类活动强度空间分异的体现。因上游 (宝鸡峡以上) 地处秦岭北麓, 植被覆盖率高, 水源涵养能力强, 河流自净能力好, 且人类口密度低, 工业、农业活动强度小, 污染物排放总量低 (夏小强等, 2024); 中下游进入关中平原后, 地形平坦导致污染物迁移扩散受阻、易滞留堆积, 同时该区域作为人口密集、工业农业集中的核心经济带, 城乡工矿用地扩张增加了地表径流污染负荷, 河岸化工企业排放与农业面源污染 (冬小麦 - 夏玉米轮作导致的持续污染输

入) 叠加, 导致水质下降 (Li et al., 2023; 刘凯等, 2025)。值得关注的是, NH₃-N 和 TP 变异系数分别达 1.16 和 0.71, 显著高于 DO (0.19), 表明这两项指标受生活污水排放和农业活动的影响更为强烈, 需作为重点管控因子。

3.2 预测模型输入因子选择分析

DO 作为反映水体自净能力与生态健康的核心指标, 其浓度受多重因子调控 (苏辉锋等, 2023), Pearson 相关性分析显示 DO 与水温、电导率、pH 值、TN 呈极强相关 ($|r|>0.8$), 与浊度中等相关 ($0.4 \leq |r|<0.5$), 与 TP 弱相关 ($0.2 \leq |r|<0.3$), 而与 NH₃-N 极弱相关 ($|r|<0.2$)。各因子影响机制符合水环境化学原理: 水温通过影响水体溶解气体饱和度和微生物活性, 直接调控 DO 生成与消耗 (欧阳潇然等, 2013); 电导率与水体离子浓度相关, 间接反映污染物负荷 (Al Sharifi et al., 2024); pH 值则通过改变水生生物代谢效率, 影响光合作用与呼吸作用过程中的 DO 交换 (李英杰等, 2009), TN 作为生源要素, 其含量变化与藻类生长繁殖密切相关, 进而通过光合作用和呼吸作用影响 DO 浓度 (李胜男等, 2020)。剔除 NH₃-N 后选择 6 项指标构建输入因子集, 有效提升模型的预测效率与精度。需注意的是 Pearson 法仅反映线性关联, 对于可能存在的非线性相关因子 (如 TP 与 DO 复杂相互作用), 需后续研究结合互信息法优化非线性关联, 以更全面捕捉因子间的关联特征。

3.3 模型性能对比及优化机制分析

模型对比显示, SSA-LSTM 预测精度与稳定性最优, 源于网络结构与超参数双重深度优化 (于珍珍等, 2022)。传统 LSTM 训练集拟合良好 (R²=0.92), 测试集误差显著攀升 (RMSE=1.30, R²=0.73), 存在过拟合, 归因于其超参数缺乏自适应寻优机制, 导致模型在应对水质非线性波动时泛化能力受限 (Qiu et al., 2023); GRU 简化门控结构缓解过拟合 (R²=0.81), 但受限长序列特征提取能力, 其在捕捉溶解氧浓度极值点时的精度仍有待提升。SSA 通过全局寻优实现参数最优配置 (周玉等, 2024),

使 SSA-LSTM 训练集与测试集 RMSE 分别降至 0.34 和 0.39, R^2 均逼近 0.95, 可精准捕捉 DO 峰谷波动, 对汛期冲击等水质突变场景具有重要预警价值。GRU 模型精度不足, 但计算成本低、响应快, 在资源受限或对实时性要求极高场景下仍具应用潜力。综上, SSA-LSTM 适合高精度预测需求, 而 GRU 适合快速响应场景, 该性能排序为同类研究的模型选型提供科学参考。

4 结论

2021—2023 年渭河关中段水质整体稳定, WQI 优良率超 97%, 时空分布呈“上游优于中下游”“夏季较差”特征, $\text{NH}_3\text{-N}$ 和 TP 波动显著。基于 DO 与水温等各因子相关性, 对比 LSTM、GRU 及 SSA-LSTM3 种模型发现, SSA-LSTM 可克服过拟合, R^2 近 0.95, 为 DO 最优预测模型。本研究阐明水质时空演变驱动机制、构建高精度预测模型, 可为流域水质动态监测预警、重点因子管控提供支撑, 助力黄河流域生态保护与高质量发展。

参考文献

- 白冰, 董飞, 彭文启, 等. 2025. 基于 EDM-LSTM 的南水北调中线水质分析预测[J]. 环境科学, 46(8): 1-13.
- 陈慧, 黎小红, 谢建枝, 等. 2025. 基于 WQI 和多元统计分析的官厅水库水质评价[J]. 环境科学与技术, 48(6): 185-197.
- 郭燕, 赖锡军. 2021. 基于循环神经网络的洞庭湖水位预测研究[J]. 长江流域资源与环境, 30(3): 689-698.
- 何勇, 张开雯. 2024. 基于 EMD-SSA-LSTM 模型的城市轨道交通站点客流预测[J]. 武汉理工大学学报(交通科学与工程版), 48(5): 829-834.
- 李振涵, 李静文, 于洪伟, 等. 2024. 汾河流域水生态环境保护与可持续发展策略研究[J]. 环境科学学报, 44(8): 1-11.
- 刘怡, 雷淑兰, 赵家宇, 等. 2023. 城市化快速发展区河水水化学特征及其形成机制[J]. 环境科学学报, 43(7): 70-80.
- 刘凯, 刘锋, 彭英湘, 等. 2025. 基于机器学习模型的流域水质评价与预测[J]. 环境污染与防治, 47(7): 1-10.
- 李海华, 肖保增, 靳凯丽, 等. 2024. 黄河三门峡水库水质预测模型构建及对比分析[J]. 环境工程, 42(12): 1-7.
- 罗清月, 魏健, 张小武, 等. 2025. 吕梁市三川河汛期常规污染物负荷贡献率及溯源研究[J]. 环境科学研究, 38(11): 2409-2421.
- 李英杰, 胡小贞, 胡社荣, 等. 2009. 草、藻型湖泊水体生态及理化特性的实验对比[J]. 生态环境学报, 18(5): 1649-1654.
- 李胜男, 熊丽萍, 彭华, 等. 2020. 东洞庭湖浮游藻类粒级结构组成及其关键影响因素[J]. 湖泊科学, 32(5): 1508-1518.
- 欧阳潇然, 赵巧华, 魏瀛珠. 2013. 基于 FVCOM 的太湖梅梁湾夏季水温、溶解氧模拟及其影响机制初探[J]. 湖泊科学, 25(4): 478-488.
- 孙天一, 李典鹏, 李启明, 等. 2024. 巢湖十八联圩湿地浮游动物群落动态及水质评价[J]. 湿地科学与管理, 20(4): 37-43.
- 石晴宜, 董增川, 罗赞, 等. 2021. 基于机器学习方法的洪泽湖入湖水水质评价及预测研究[J]. 中国农村水利水电(12): 53-59.
- 苏辉锋, 丁乐声, 王绪旺, 等. 2023. 基于 CNN-GRU 混合模型的养殖工船水体溶解氧预测研究[J]. 南方水产科学, 19(4): 174-180.
- 孙迎迎, 马晓敏. 2025. 新汴河流域水质时空变化特征及驱动因素研究[J]. 水资源开发与管理, 11(7): 1-8.
- 唐琦, 刘兵, 王璞, 等. 2022. 改进 WQI 在川中丘陵地区典型流域水质评价中的应用: 以琼江流域上游段为例[J]. 环境工程技术学报, 12(2): 615-623.
- 夏诗语, 吕文, 杨金艳, 等. 2025. 苏州市河流水质时空分布特征及影响因素分析[J]. 环境科学, 46(7): 4241-4250.
- 夏小强, 张乐, 要丽娟, 等. 2024. 基于 AHP-模糊综合评价法的渭河河流健康评价[J]. 西北大学学报(自然科学版), 54(3): 413-423.
- 杨坪宏, 胡奥, 崔东文, 等. 2023. 基于数据处理与若干群体算法优化的 GRU/LSTM 水质时间序列预测[J]. 水资源与水工程学报, 34(4): 45-53.
- 于珍珍, 邹华芬, 于德水, 等. 2022. 基于 SSA-LSTM 的玉米土壤含氧量预测模型[J]. 农业机械学报, 53(11): 360-368.
- 郑立地, 涂年旺, 叶晨, 等. 2025. 福建永安龙头国家湿地公园水质时空特征及评价[J]. 湿地科学与管理, 21(1): 52-57.
- 左韧, 李海波, 刘芄, 等. 2024. 大冶湖沉积物-上覆水界面氮磷交换通量的冬夏对比[J]. 环境工程学报, 18(6): 1520-1530.
- 周玉, 房倩, 裴泽宣, 等. 2024. 基于改进麻雀搜索算法优化 LSTM 的滚动轴承故障诊断[J]. 工程科学与技术, 56(2): 289-298.
- Al Sharifi S R, Zwain H H, Hasan Z K. 2024. Evaluating surface water quality of Euphrates River in Al-Najaf Al-Ashraf, Iraq with water quality index (WQI)[J]. Engineering, Technology & Applied Science Research, 14(4): 15022-15026.
- Bibi H, Saleem S, Jalil Z, et al. 2025. Riverine Flood prediction and early warning in mountainous regions using artificial intelligence[OL]. <https://arxiv.org/pdf/2505.18645>.
- Han X M, Boota M W, Soomro S-e-h, et al. 2024. Water strategies and management: current paths to sustainable water use[J]. Applied Water Science, 14(7): 154.
- Li Y, Mi W J, Ji L, et al. 2023. Urbanization and agriculture intensification jointly enlarge the spatial inequality of river water quality[J]. Science of the Total Environment, 878: 162559.
- Nallakaruppan M, Gangadevi E, Shri M L, et al. 2024. Reliable water quality prediction and parametric analysis using explainable AI models[J]. Scientific Reports, 14(1): 7520.
- Pang J F, Luo W, Yao Z Y, et al. 2024. Water quality prediction in urban waterways based on wavelet packet Denoising and LSTM[J]. Water Resources Management, 38(7): 2399-2420.
- Pesce S F, Wunderlin D A. 2000. Use of water quality indices to verify the impact of Córdoba City (Argentina) on Suquia River[J]. Water research, 34(11): 2915-2926.
- Qiu P C, Liu F, Zhang J M. 2023. Land subsidence prediction model based on the long short-term memory neural network optimized using the sparrow search algorithm[J]. Applied Sciences, 13(20): 11156.
- Guo L, Luo W, Tian Q Q. 2024. Water quality prediction in the Yellow River source area based on the DeepTCN-GRU model[J]. Journal of Water Process Engineering, 59: 105052.