



中国食品学报

Journal of Chinese Institute of Food Science and Technology

ISSN 1009-7848, CN 11-4528/TS

《中国食品学报》网络首发论文

题目：人工智能在食品微生物检测中的应用与展望
作者：曲天铭，王娉，赵晓美，姬庆龙，陈颖
网络首发日期：2026-05-15
引用格式：曲天铭，王娉，赵晓美，姬庆龙，陈颖. 人工智能在食品微生物检测中的应用与展望[J/OL]. 中国食品学报.
<https://link.cnki.net/urlid/11.4528.TS.20260515.1133.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

人工智能在食品微生物检测中的应用与展望

曲天铭, 王娉, 赵晓美, 姬庆龙, 陈颖^{✉1}

(中国质量检验检测科学研究院 北京 100176)

*通信作者 陈颖

摘要 人工智能(AI)技术的突破性发展,为食品微生物检测领域带来了革命性变革。本文综述 AI 技术在食品微生物检测中的关键技术进展与创新应用,重点概述基于深度学习的显微图像分析、拉曼光谱-机器学习联用检测、宏基因组智能解析及强化学习驱动的培养调控技术等核心技术。这些技术通过特征提取优化和算法迭代创新,显著突破传统检测方法在速度、灵敏度和通量等方面的技术瓶颈,如卷积神经网络(CNN)可将菌落计数效率提升至分钟级,Transformer 模型对抗生素抗性基因的预测准确率相较于传统方法可提升至 90%以上。然而, AI 技术的实际应用仍面临多重制约,比如数据样本的偏差性、算法黑箱效应与可解释性缺失,不同种类食品基质之间的差异,进而形成的泛化性能不足等问题亟待解决,特别是现有深度学习模型与现行监管体系的技术适配度仍需提升。展望未来,智能化的食品微生物检测技术需要与产业需求深度融合,推动 AI 微生物检测体系向更高效、更可靠的方向发展。构建“技术研发-标准制定-产业应用”三位一体的协同创新体系,重点发展多模态数据融合算法和自适应检测模型,通过建立食品微生物特征数据库和可解释性 AI 框架,推动检测技术向智能化、标准化方向演进,最终实现从原料溯源到消费终端的全链条食品安全智能监管体系升级。

关键词 人工智能; 食品微生物检测; 食品质量; 食品安全; 机器学习

Applications and Prospects of Artificial Intelligence in Food Microbiological Testing

QU Tianming, WANG Ping, ZHAO Xiaomei, JI Qinglong, CHEN Ying[✉]

(Chinese Academy of Quality and Inspection & Testing, Beijing 100176)

Abstract Artificial intelligence (AI) has revolutionized food microbiological testing through significant technological advances. This review highlighted core innovations including deep learning-enhanced microscopic imaging, machine learning-integrated Raman spectroscopy, intelligent metagenomic analysis, and reinforcement learning-optimized culture systems. These AI-driven approaches demonstrated superior performance in processing speed, sensitivity, and throughput compared to conventional methods. Convolutional neural networks achieved minute-level colony enumeration efficiency, while Transformer models attained over 90% accuracy in antibiotic resistance gene prediction. However, challenges persist regarded data biases, algorithmic interpretability limitations, and generalizability across diverse food matrices. Current systems particularly required improved compatibility with regulatory frameworks. Future development necessitates deeper integration of industrial needed through multimodal data fusion algorithms and adaptive detection models. Establishing comprehensive microbial databases and interpretable AI architectures would facilitate standardized intelligent testing systems, enabling end-to-end food safety monitoring from production to consumption.

Key words artificial intelligence; food microbiological testing; food quality; food safety; machine learning

食品的质量与安全是保障消费者权益及健康的重要基础,在食品中微生物的污染往往是导致其腐败变质、爆发食源性疾病的关键因素。当前在复杂的食品基质中直接鉴别微生物污染(致病菌、致腐

基金项目:中国博士后科学基金资助项目(2024M763116);国家市场监督管理总局科技创新人才计划项目(QNBJ202327);中国质量检验检测科学研究院基本科研业务费项目(2025JK062)

作者简介:曲天铭,男,博士,助理研究员

网络首发时间:2026-05-15 15:12:16 网络首发地址: <https://link.cnki.net/urlid/11.4528.TS.20260515.1133.002>

菌)仍具有一定的挑战,解决这些挑战需要高灵敏、高特异性的生物标志物及可实现早期检测的检测技术。随着食品行业的高速发展以及消费者对于食品质量安全的认知提升,更快速、精准和高通量的微生物检测技术变得至关重要^[1]。近年来,人工智能(AI)技术的飞速发展,例如机器学习(ML)和深度学习(DL)算法在微生物图像识别、基因组数据挖掘和微生物污染模式预测方面取得的研究进展,使得更高效、更准确的检测分析方法成为可能^[2]。AI技术可从大量、复杂且多维度的微生物数据中提取关键信息,并进行自动化分析、实时监控和智能决策,从而大幅度提高其检测的效率。例如,基于卷积神经网络(CNN)的显微图像分析系统,可在几分钟内完成菌落计数和分类^[3],以及通过AI与宏基因组技术融合,可以快速精准地识别食品中的病原体及耐药基因,这些快速发展的算法与技术为食品质量安全检测提供了全新的工具^[4]。

人工智能在食品微生物检测中的应用不仅限于实验室阶段的研究,还应覆盖从原料到产品,从生产端到消费端的全链条风险管控。基于AI的食品安全实时监控系统的搭建,通过传感器数据分析及预测对食品加工过程中的微生物污染作出及时预警^[5-6]。基于时间/温度模型的算法,通过动态评估致腐微生物的生长趋势,从而在食品冷链物流过程中优化储运策略^[7-8]。基于AI图像识别的便携式传感/荧光检测设备,也具有在食品销售期间进行现场快速筛查的优势,有助于提升产品质量安全监管及现场检测效率^[9-10]。

然而,当前AI技术在食品微生物检测中的应用仍面临着数据标准化不足,模型可解释性有限以及跨平台兼容性差等挑战。本综述将系统梳理AI技术在食品微生物检测中的最新进展,分析其技术优势和应用情况,并对AI-食品微生物检测的未来应用情况进行讨论,旨在为食品质量安全检测领域的智能化转型提供理论参考。

1. 食品微生物检测中的AI算法体系及数据生态

1.1 算法体系架构

监督学习(Supervised learning)通过建立输入-输出的映射关系实现微生物特征与检测目标的精准关联,包括支持向量机(Support vector machine)和随机森林(Random forest)等传统算法被广泛应用于光谱特征解析和基因序列分类^[11-12],在处理小样本数据时具有良好的性能,表现出较强的泛化性,通过结合微生物的基因组特征和环境参数,可以快速识别食源性致病菌及其耐药性。无监督学习(Unsupervised learning)则无需预先标记训练数据,可以自动发现并处理数据中的潜在模式,通过降维和可视化[主成分分析(PCA)、线性判别分析(LDA)等]技术,可以直观地显示不同食品样本微生物组成的异同,并且分析过程中没有参数限制,去除了数据冗余和噪声,对数据进行了压缩和预处理,使数据集更易于使用,结果更易于理解,这也将有助于进一步了解微生物在食品中的动态变化规律。

深度学习(Deep learning, DL)算法通过构建和训练深度神经网络来促进数据采集和模式识别。与传统机器学习相比,DL的分析维度更高,旨在捕捉原始数据中尽可能多的/完整的关系,主要涵盖了人工神经网络(ANN)、卷积神经网络(CNN)和循环神经网络(RNN)等架构。DL通常需要大量数据集才能进行有效训练以捕捉复杂模式,尤其擅长处理高维数据,其在微生物图像分析领域的开发,也进一步完善了传统的显微检测方法产生的偏差效应^[13-15]。这些深度学习算法与自动化显微成像系统的结合,正在推动食品微生物检测向智能化、高通量的方向发展。然而,这些深度学习算法在可解释性方面,通常被视为“黑箱”,使得阐明其内部机制具有挑战性。

当前应用于食品微生物检测的AI技术已经覆盖了从显微图像识别、基因序列分析及小分子靶标物质挖掘等全范围,并显著提高了检测的效率和准确性。这些算法通过处理多重复杂的微生物数据,为食品安全风险预警和质量控制提供了新的技术手段。图1展示了食品微生物分析过程中用到的主要的算法体系及其典型处理方法,为了解人工智能技术在食品微生物安全领域的应用提供了清晰的技术框架。




图 1 应用于微生物检测的基础算法体系及处理方式
Fig.1 Basic algorithmic systems and processing applied to microbiological testing

1.2 数据生态系统

在食品微生物检测领域，人工智能的应用高度依赖多重复杂数据的融合与处理。AI 模型的训练需要细菌显微图像、基因组信息、蛋白质代谢物信息数据以及环境参数等不同形式的的数据共同提供训练基础。因此，这些数据处理的标准化程度将会直接影响 AI 模型的准确度。例如在宏基因组测序过程中，产生的海量序列数据需要经过生物信息学处理，对下机数据进行质量控制、组装和注释，这些预处理步骤直接影响 AI 模型的性能；拉曼光谱和红外光谱等检测技术生成的谱图也要求算法具备处理高维非线性特征的能力。此外，不同的食品基质（如肉类、乳制品和蔬菜）中微生物群落的特征差异较大，这要求数据样本具有代表性和多样性，以避免模型在实际应用中的偏差。

2. AI 技术在食品微生物检测中的发展与应用现状


2.1 微生物的智能快速检测

随着 AI 图像识别技术的发展，基于深度学习的微图像识别算法正在逐步代替传统的手动显微检测方法。包括 Ma 等^[16]和 Naets 等^[17]采用实时目标检测和分类（YOLO）算法和 Mask R-CNN 架构等，实现亚像素级的菌落边缘检测，即使在菌落重叠或杂菌干扰的情况下也能保持 94%左右的计数、识别准确率。在细菌形态分类方面，Kang 等^[18]建立了一种新颖的 3D-GhostNet 算法被应用于高光谱显微成像（HMI）的数据分析，以改进食源性致病菌的分类，在识别 4 种不同食源性细菌细胞的任务中，3D-GhostNet 实现了 100%的准确率，并且在识别复杂的病原体混合物方面仍然具有良好的鲁棒性。此外，全新成像系统结合数字全息显微技术，通过 AI 算法能够重建微生物的三维形态特征^[19]，也将为食品中微生物的快速识别提供新的维度。

表面增强拉曼光谱（SERS）作为一种快速可靠的细菌检测方法，其优势在于能够提供归因于细菌细胞成分（包括核酸、细胞壁和细胞膜）的独特光谱指纹。然而，其光谱峰值比例、强度和波数偏移的变化非常细微，难以手动进行辨别。Rho 等^[20]首次将 SERS 与深度学习相结合，通过实施一种高精度、新开发的深度学习模型—双分支宽核网络（DualWKNet），并通过五重交叉验证，在细菌光谱分类的准确率达到 98%。Ho 等^[21]在研究过程中构建了一个庞大的细菌拉曼光谱数据集，并结合深度

残差网络 (ResNet) 准确识别了 30 种常见的细菌病原体, 能实现超过 82% 的平均分离株级准确度。

机器学习等算法因为它具有相关数据挖掘能力、非线性响应最小化能力和降噪效率高的优势, 已被广泛用作微生物传感数据分析的替代方案, 以克服传感器的缺点。Liang 等^[22]开发的一种基于智能手机的无线荧光显微镜成像系统, 采用 XGBoost 算法对牛奶中的 4 种细菌和水中的 10 种细菌分别获得了 91.67% 和 83.75% 的预测准确率。此外, Li 等^[23]建立的 BaseNet 工具包, 通过使用 Transformer 模型对纳米孔测序产生的电信号进行解析, 可在 1 h 内完成病原体的物种水平的鉴定。这些基于 AI 技术的创新共同形成了食品微生物快速检测的多维方法。



注: A 图为采用深度学习算法 You Only Look Once v4 (YOLOv4) 对微菌落进行定位和分类^[16]; B 图为基于高光谱显微成像的数据分析流程 3D-GhostNet, 用来进行食源性致病菌的分类检测^[18]; C 图为基于深度神经网络的 SERS 分析, 在无需分离的情况下识别细菌^[20]; D 图为基于 Transformer 的纳米孔测序信号解码工具包 BaseNet 的工作流程^[23]。

图 2 人工智能技术在微生物快速检测中的应用
Fig.2 Application of artificial intelligence technology in rapid microbial detection


在乳及乳制品生产线的应用中, 基于深度学习驱动的显微图像分析系统, 在较高灵敏度下早期快速识别原料乳或产品中金黄色葡萄球菌和沙门氏菌等高风险食源性致病菌^[24-25]。该系统通过结合活性染色和图像特征提取, 实现了对活菌与死菌的区分, 弥补了传统 PCR 方法在判定菌体活性的不足。这种 AI 质检方案可将检测时间从数十小时缩短至分钟级, 同时保持 99% 以上的种间特异性^[25]。同时, 利用微生物霰弹枪宏基因组学数据及人工智能方法作为乳品生产中的非靶向筛选工具, 能够检测出牛奶生产中的异常情况, 该流程结合 XGBoost 算法通过微生物组成情况智能判别乳品的质量安全情况 (乳品的加工状态、污染菌及乳品中含抗生素的情况)^[26]。

2.2 微生物基因组智能解析

宏基因组分箱组装 binning 算法的出现标志着食品微生物组的研究进入了一个新阶段。MetaBAT2 算法采用了自适应分箱策略和集成学习方法, 能够在复杂的食品样本中恢复细菌基因组的完整度超过 90%^[27]。在宏基因组分箱过程中使用变分自编码器 (VAMB), 在序列聚类之前编码序列共丰度和 k-mer 分布信息, 能够在无需任何数据集知识的情况下整合这 2 种不同的数据类型, 在模拟数据中重建了 98% 以上近完整的基因组^[28]。在最新的研究中 Wang 等^[29]开发了一种基于对比多视图表示学习的

分箱方法——COMEBin，其利用数据增强为每个重叠群生成多个片段，并通过对比学习获得异构特征的高质量嵌入。在对模拟数据和真实数据的验证中 COMEBin 的表现优于最先进的分箱方法。这些进展使得从食品样本中直接获取高质量的微生物基因组成为可能，为食品安全风险检测提供了强有力的手段。

细菌抗生素抗性基因的预测也正经历从规则匹配到深度学习的转变。如 TransAMR 是基于 Attention 机制的 Transformer 模型，能够捕捉基因序列中的远程依赖关系，模型在预测 AMR 方面实现了高出 10% 的曲线下面积（AUC），并且优于传统的 ML 模型，大幅度提高预测的准确度^[30]。同样的，Abbas 等^[31]利用 Transformer 模型构建的 Trans-ARG 利用预训练的 ESMFold 模型从蛋白质序列中提取嵌入，从而捕获复杂的结构和功能信息，在测试数据集上实现了 90.96% 的准确率和 97.08% 的 AUC 得分。这种集成方式使模型很好地泛化至不同的蛋白质序列上，能够显著提高模型对不同抗性机制的识别能力，为细菌的抗性检测提供了更全面的支持。在微生物基因功能注释方面，AI 技术的发展同样取得了重要进展，Madani 等^[32]通过分析 19 000 个蛋白质家族的 2.8 亿蛋白质序列，构建了基于深度学习语言模型的 ProGen，可以生成跨大型蛋白质家族且功能可预测的蛋白质序列，能够实现对新发基因的功能进行准确预测。知识图谱技术（Knowledge graph）基于其“实体-关系-实体”的三元组单位，构建基因-代谢途径-表型之间的多维关联网络，为系统理解食品微生物的功能提供了新的研究思路，能够实现对微生物特性的系统性解析。基于知识图谱的整合分析方法能够将分散的食品组学数据与表型特征建立关联，从而揭示微生物特征、功能及其内在机制。这种系统生物学的研究思路，使得研究能够从单纯的微生物组成描述，发展到对其功能的预测和调控，显著推动了食品微生物的靶标识别及检测技术发展。目前，基于知识图谱技术的应用已经在食源性致病菌风险检测、微生物发酵剂筛选等多个领域，为食品安全和质量控制提供了新的研究方向。



注：A 图为宏基因组分箱 COMEBin 的通用工作流程^[29]；B 图为 TransAMR 准确预测抗生素耐药性及可视化的步骤^[30]；C 图为用于预测抗生素耐药基因的 Trans-ARG 模型工作流程^[31]。

图 3 人工智能技术在微生物基因组解析中的主要应用
Fig.3 The main applications of artificial intelligence technology in microbial genome analysis


在肉及肉制品的质量安全检测应用中，AI 与全基因组测序的结合形成了“高精度分型+溯源追踪”的新范式^[33]。针对李斯特菌的特异性基因标记识别算法，已经能够在单菌株水平上定位环境污染源，并支持从原料到成品的全过程追溯^[6]。实践表明，该方法可将污染源调查时间缩减至原先的十分之一左右，极大提高了应急响应效率。此外，在冷链物流过程中，微生物风险预警系统通过融合温度监测、包装材料特性与微生物生长动力学模型，实现了动态预测。基于深度学习的时序模型对冷链食品货架期的预测误差已被控制在 12 h 以内，明显优于传统经验公式（通常误差 3~5 d），为供应链的

温控管理和损耗控制提供了可靠依据^[34-35]。

2.3 微生物代谢标志物智能挖掘

在后基因组学时代,代谢组学已成为功能基因组学的有力工具,并在医学、微生物学、食品科学等不同领域得到广泛应用^[36-37]。微生物的代谢组学与其表型直接相关,可以全面反映微生物在不同环境条件下的变异,从而有效区分细微的差异^[38]。随着 AI 技术的发展,显著提升了代谢组学数据的处理效率与生物标志物的挖掘能力。尤其是基于深度学习的算法,不仅在解决数据预处理、代谢物鉴定和生物标志物筛查方面展现出巨大潜力,而且在多组学整合分析、通路预测和调控机制综合映射中也发挥着关键作用^[39-40]。

在非靶向代谢组学数据处理过程中,深度学习算法在去噪和基线校正、保留时间(RT)对齐、假峰检测、库搜索等方面已经展现出良好的性能(图 4A)。例如,在峰值检测中,Melnikov 等^[41]通过引入“Peakonly”算法来处理峰值检测和积分,收集了手动标记数据集的 4 000 多个感兴趣区域(ROI),基于 CNN 模型将原始 LC-MS 数据分类为代表噪声、化学峰和模糊峰的片段。Gloaguen 等^[42]利用 CNN 在数量和比例上减少虚假峰的出现,建立了 NeatMS 工具,并且证实了其在峰值管理方面优于其它工具,以最少的计算资源在几分钟内实现数据的分析。此外,深度学习算法已被开发用于挖掘潜在的生物标志物和生理参数。深度学习模型“DNN-MDA”通过整合代谢通路信息与高维数据特征,实现了对病原微生物特异性代谢物的精准识别(图 4B),克服了传统统计方法在复杂食品基质中灵敏度不足的局限^[43]。结合代谢指纹图谱分析与 CNN 的算法展现出对食源性致病菌(单核细胞增生李斯特菌)及其血清型的高效分类能力(图 4C),预测准确率可达 96%以上^[44]。



注: A 图为采用深度学习在高分辨率 LC-MS 数据中实现精确峰值检测^[41]; B 图为 DNN-MDA 在微生物生物标志物挖掘中的应用^[43]; C 图为 CNN 在单增李斯特氏菌血清型分类过程中的应用^[44]。

图 4 人工智能技术在微生物代谢组分析中的主要应用

Fig.4 Major applications of artificial intelligence techniques in microbial metabolome analysis

2.4 微生物智能化培养

应用强化学习可以获取微生物的最佳培养条件,通过与环境的持续互动,深度确定性策略梯度算法(DDPG)可以自主探索理想的细菌培养参数,这些参数是传统经验方法难以确定的。Treloar 等^[45]

通过计算机模拟证明了强化学习在连续生物反应器内控制共培养的有效性。Mendiola-Rodriguez 等^[46]探索了 DDPG 算法在不同场景下应用于厌氧消化系统的可行性,以优化沼气生产过程中微生物需氧量的降低,证明了该算法可以有效提取发酵系统中的关键参数信息并进行优化调整。这些算法在发酵过程中可以缩短发酵周期,并大大提高产能。利用多目标强化学习框架,可以同时优化生长速率、产品浓度和能耗等多个变量,从而实现培养过程的智能平衡。

3. AI 在食品微生物检测中的挑战与对策

3.1 数据偏差

当前食品微生物数据生态面临着数据标准化问题和小样本学习问题的关键挑战。由于不同实验室采用的测序手段(如 16S rRNA 测序与全基因组测序)和测序平台(Illumina 与 PacBio)存在显著差异,以及不同实验室采用的序列质控、组装及注释的阈值间存在差异,导致数据间存在系统性偏差。在小样本学习方面,针对食品中较低丰度的病原菌或新发病原菌的检测模型开发往往受限于可获得的确证样本量。近期研究表明,使用自迁移深度学习(Self-transfer deep learning)策略通过构建包含常见食源性致病菌的预训练模型,再使用少量目标菌株数据进行微调,可使模型在保持对常见菌株识别能力的同时,将稀有菌株的检测灵敏度大幅度提升,同时识别食源性致病菌的革兰氏阴性菌、阳性菌、属水平及种水平,准确率超过 99.99%,菌株识别准确率超过 99.49%^[47]。此外,针对 AI 的数据偏差问题,联邦学习(Federated learning, FL)作为一种分布式机器学习过程,允许多个节点协同训练共享模型,而无需云端提交原始数据。通过将数据保持在本地并仅通过通信网络交换模型更新,它提供了数据隐私、安全性、效率和可扩展性等关键优势^[48]。Konečný 等^[49]建立的分布式机器学习平台,整合了 200 余家机构的检测数据,使模型在跨平台测试中的性能误差降低^[50]。当前 FL 在食品安全检测领域的主要应用包括水质、牛奶质量、化学风险、食品欺诈等方面^[51],进一步有望通过整合更多食品样本类型及数据源,使人工智能模型跨基质的误差降低。

3.2 算法的可解释性

在当前使用 AI 进行微生物检测的过程中,算法“黑箱”问题也日益凸显^[52-53],根据欧盟最新颁布的《人工智能法案》要求,凡涉食品安全等高风险领域的 AI 系统,都必须提供可追溯、可解释的决策依据^[54];现行的深度神经网络算法通常难以满足这一要求。这两大挑战不仅阻碍了 AI 检测技术的广泛应用,也为政府监管和产业推广带来了严峻考验。在 AI 算法可解释性方面,可解释人工智能(Explainable artificial intelligence)领域致力于开发使 AI 算法能够对其结果进行解释,使人类用户能够理解、恰当地信任并生成更易解释的模型,正在逐步满足监管的需求^[55]。沙普利加和解释(Shapley additive explanations, SHAP^[56])和局部可解释模型无关解释方法(Local interpretable model-agnostic explanations, LIME^[57])等技术的改进版本已能可视化微生物检测过程中关键特征指标,如检测细胞因子风暴与患者 COVID-19 严重程度之间的关系,以确定每种细胞因子如何导致 COVID-19 的严重程度,从而可能鉴定出有助于治疗决策和疫苗开发的多种细胞因子^[58]。

3.3 技术的产业化应用

在 AI 模型的实际应用过程中,食品基质的多样性对其提出了更高要求。高脂乳制品、高糖果蔬汁、肉制品的固体性质等不同样本在光学、光谱或基因组信号上存在显著差异。在分析的过程中若直接将某一类基质上训练的模型应用于其他基质,检测准确率将大幅下降^[59]。面对 AI 模型跨食品基质泛化能力差的问题,需要针对不同食品类别设计专用预处理通道或开发自适应算法,以保证跨基质的鲁棒性。与此同时,食品生产加工现场对检测速度的严格需求,使得 AI 推理的延迟必须控制在毫秒级或以下。轻量化网络架构与模型量化技术成为关键手段:在保证 $\geq 95\%$ 准确率的前提下,将单次推理时间优化至数十毫秒,才是满足高通量生产线实时监测需求的关键。

此外,针对于 AI 工具的统一的性能评估和验证体系是必不可少的,从灵敏度、特异性、响应速度到长期稳定性等多维度进行考量,还要兼顾设备与生产线的无缝集成和成本效益,确保 AI 检测模

块能够平滑接入现有流程,并具备易于维护和升级的特性。在应用模式上,“AI 预筛查+传统确认”的策略更容易被接受:AI 系统用于高频、快速的初筛,传统培养或分子方法则作为结果辅助验证,以兼顾效率与可靠性。

4. 未来展望

基于人工智能的新型微生物检测技术有望更快、更准确地识别食源性致病菌,对各种微生物数据集的实时分析可以增强病原的早期检测。在未来,食品微生物检测专属 AI 大模型将成为技术突破点,通过预训练大量科研文献和收集检测数据,能够跨平台、跨基质精准检测;能够在未知病原体识别任务上的零样本学习达到较高准确度。即这类模型通过微调即可适应各类细分场景,如乳品厂可基于通用模型快速开发针对特定生产线的定制化检测模块。同时,AI 的进一步发展将有助于深入地了解复杂基质的微生物组信息,使得食品微生物组与食品基质间的互作关系变的清晰,并且多组学数据与人工智能分析的整合可以揭示微生物生态系统内复杂的关系。同时 AI 可以帮助识别新型抗菌化合物并开发有针对性的治疗方法,预测模型可以帮助预测耐药菌株的出现,指导主动采取措施应对抗菌药物耐药性。

AI 技术的发展正在逐渐重构食品微生物检测的范式,由离散的检测节点进化为贯穿全链条的智能监测网络。然而,技术突破必须与标准体系、产业需求同步演进。建议从以下 3 方面推进:1)建立跨学科的 AI 验证基准;2)发展适应现场检测的微型化检测设备;3)构建开放共享的微生物行业数据池。只有通过“技术-标准-产业”的协同进化,才能充分释放 AI 在食品质量安全领域的变革潜力,实现“从农场到餐桌”的智能化食品质量与安全控制。

参考文献

- [1] 万其武, 包旭东, 丁柯, 等. 微流控技术在病原微生物检测中的研究进展[J]. 生物技术通报, 2023, 39(10): 107-114.
WAN Q W, BAO X D, DING K, et al. Research progress in microfluidic technology in the detection of pathogenic microorganisms[J]. Biotechnology Bulletin, 2023, 39(10): 107-114.
- [2] 余泽浩, 张雷明, 张梦娜, 等. 基于人工智能的药物研发: 目前的进展和未来的挑战[J]. 中国药科大学学报, 2023, 54(3): 282-293.
YU Z H, ZHANG L M, ZHANG M N, et al. Artificial intelligence-based drug development: Current progress and future challenges[J]. Journal of China Pharmaceutical University, 2023, 54(3): 282-293.
- [3] ZHANG J, LI C, RAHAMAN M M, et al. A comprehensive review of image analysis methods for microorganism counting: From classical image processing to deep learning approaches[J]. Artificial Intelligence Review, 2022, 55(4): 2875-2944.
- [4] GAO Y Q, LIU M. Application of machine learning based genome sequence analysis in pathogen identification[J]. Frontiers in Microbiology, 2024, 15: 1474078.
- [5] SOBHAN A, HOSSAIN A, WEI L, et al. IoT-enabled biosensors in food packaging: A breakthrough in food safety for monitoring risks in real time[J]. Foods, 2025, 14(8): 1403.
- [6] OLUFEMI O I, AYENI O, OLAGOKE-KOMOLAFE O E. Advancing real-time predictive systems for *Listeria* and *E. coli* detection in meat processing facilities across the USA[J]. International Journal of Multidisciplinary Research and Growth Evaluation, 2024, 5(6): 1504-1514.
- [7] EZE J, DUAN Y, EZE E, et al. Machine learning-based optimal temperature management model for safety and quality control of perishable food supply chain[J]. Scientific Reports, 2024, 14(1): 27228.
- [8] SHEHZAD K. Predictive AI models for food spoilage and shelf-life estimation[J]. Global Trends in Science and Technology, 2025, 1(1): 75-94.
- [9] KIM K, LEE W G. Portable, automated and deep-learning-enabled microscopy for smartphone-tethered optical platform towards remote homecare diagnostics: A review[J]. Small Methods, 2023, 7(1): 2200979.
- [10] WANG B F, LI Y W, ZHOU M F, et al. Smartphone-based platforms implementing microfluidic detection with image-based artificial intelligence[J]. Nature Communications, 2023, 14(1): 1341.
- [11] ASTUTI S D, TAMIMI M H, PRADHANA A A, et al. Gas sensor array to classify the chicken meat with *E. coli* contaminant by using random forest and support vector machine[J]. Biosensors and Bioelectronics: X, 2021, 9: 100083.
- [12] MENGSI P, UNGCHAROEN R, GERTPHOL S. A machine learning and neural network approach for classifying multidrug-resistant bacterial infections[J]. Healthcare Analytics, 2025, 7: 100388.
- [13] WON Y K, KIM C H, JEON J, et al. Deep learning by Vision Transformer to classify bacterial and fungal keratitis using different types of anterior segment images[J]. Computers in Biology and Medicine, 2025, 190: 109976.
- [14] MEMON F, NAZ B, NAREJO S, et al. An artificial intelligence Vision Transformer model for classification of bacterial colony[J]. International Journal of Innovations in Science & Technology, 2024, 6(1): 237-248.
- [15] SHAKYA E, HUANG P C. Bacterial image segmentation through deep learning approach[M]// Machine Learning in 2D Materials Science. Boca Raton: CRC Press, 2023: 89-108.
- [16] MA L, YI J, WISUTHIPHAET N, et al. Accelerating the detection of bacteria in food using artificial intelligence and optical imaging[J]. Applied and Environmental Microbiology, 2023, 89(1): e01828-01822.
- [17] NAETS T, HUIJSMANS M, SMYTH P, et al. A Mask R-CNN approach to counting bacterial colony forming units in pharmaceutical

- development[PP/OL]. arXiv preprint arXiv, (2021-03-09)[2025-05-06]. <https://doi.org/10.48550/arXiv.2103.05337>.
- [18] KANG R, SUN S, OUYANG Q, et al. 3D-ghostNet: A novel spatial-spectral algorithm to improve foodborne bacteria classification coupled with hyperspectral microscopic imaging technology[J]. *Sensors and Actuators B: Chemical*, 2024, 411: 135706.
- [19] MIHAYLOVA E M. Imaging of live cells by digital holographic microscopy[C]// *Photonics*. Plovdiv, Bulgaria: MDPI, 2024, 11(10): 980.
- [20] RHO E, KIM M, CHO S H, et al. Separation-free bacterial identification in arbitrary media via deep neural network-based SERS analysis[J]. *Biosensors and Bioelectronics*, 2022, 202: 113991.
- [21] HO C S, JEAN N, HOGAN C A, et al. Rapid identification of pathogenic bacteria using Raman spectroscopy and deep learning[J]. *Nature Communications*, 2019, 10(1): 4927.
- [22] LIANG Y, LEE M H, ZHOU A, et al. eXtreme gradient boosting-based classification of bacterial mixtures in water and milk using wireless microscopic imaging of quorum sensing peptide-conjugated particles[J]. *Biosensors and Bioelectronics*, 2023, 227: 115144.
- [23] LI Q W, SUN C, WANG D Q, et al. BaseNet: A transformer-based toolkit for nanopore sequencing signal decoding[J]. *Computational and Structural Biotechnology Journal*, 2024, 23: 3430-3444.
- [24] SOARES J C, SOARES A C, POPOLIN-NETO M, et al. Detection of *Staphylococcus aureus* in milk samples using impedance spectroscopy and data processing with information visualization techniques and multidimensional calibration space[J]. *Sensors and Actuators Reports*, 2022, 4: 100083.
- [25] WANG H, CEYLAN KOYDEMIR H, QIU Y, et al. Early detection and classification of live bacteria using time-lapse coherent imaging and deep learning[J]. *Light: Science & Applications*, 2020, 9(1): 118.
- [26] BECK K L, HAIMINEN N, AGARWAL A, et al. Development and evaluation of statistical and artificial intelligence approaches with microbial shotgun metagenomics data as an untargeted screening tool for use in food production[J]. *MSystems*, 2024, 9(11): e00840-00824.
- [27] KANG D D, LI F, KIRTON E, et al. MetaBAT 2: An adaptive binning algorithm for robust and efficient genome reconstruction from metagenome assemblies[J]. *PeerJ*, 2019, 7: e7359.
- [28] NISSEN J N, JOHANSEN J, ALLESØE R L, et al. Improved metagenome binning and assembly using deep variational autoencoders[J]. *Nature Biotechnology*, 2021, 39(5): 555-560.
- [29] WANG Z Y, YOU R H, HAN H T, et al. Effective binning of metagenomic contigs using contrastive multi-view representation learning[J]. *Nature Communications*, 2024, 15(1): 585.
- [30] THARMAKULASINGAM M, WANG W, KERBY M, et al. TransAMR: An interpretable transformer model for accurate prediction of antimicrobial resistance using antibiotic administration data[J]. *IEEE Access*, 2023, 11: 75337-75350.
- [31] ABBAS M M, RANJAN A, HOU A, et al. Trans-ARG: Predicting antibiotic resistance genes with a transformer-based model and pretrained protein language model[C]// *Baton Rouge: Proceedings of the 4th International Conference on AI-ML Systems*, 2024.
- [32] MADANI A, KRAUSE B, GREENE E R, et al. Large language models generate functional protein sequences across diverse families[J]. *Nature Biotechnology*, 2023, 41(8): 1099-1106.
- [33] QU T M, WANG P, ZHAO X M, et al. Metagenomic profiles of the antimicrobial resistance in traditional Chinese fermented meat products: Core resistome and co-occurrence patterns[J]. *International Journal of Food Microbiology*, 2024, 418: 110740.
- [34] AMANI M A, SARKODIE S A. Mitigating spread of contamination in meat supply chain management using deep learning[J]. *Scientific reports*, 2022, 12(1): 5037.
- [35] NOZARI H, RAHMATY M, FOUKOLAEI P Z, et al. Optimizing cold chain logistics with Artificial Intelligence of Things (AIoT): A model for reducing operational and transportation costs[J]. *Future Transportation*, 2025, 5(1): 1.
- [36] KACHROO P, STEWART I D, KELLY R S, et al. Metabolomic profiling reveals extensive adrenal suppression due to inhaled corticosteroid therapy in asthma[J]. *Nature Medicine*, 2022, 28(4): 814-822.
- [37] WANG X, BOUZEMBRAK Y, LANSINK A O, et al. Application of machine learning to the monitoring and prediction of food safety: A review[J]. *Comprehensive Reviews in Food Science and Food Safety*, 2022, 21(1): 416-434.
- [38] BUNDY J G, WILLEY T L, CASTELL R S, et al. Discrimination of pathogenic clinical isolates and laboratory strains of *Bacillus cereus* by NMR-based metabolomic profiling[J]. *FEMS Microbiology Letters*, 2005, 242(1): 127-136.
- [39] TSIMENIDIS S, VROCHIDOU E, PAPAKOSTAS G A. Omics data and data representations for deep learning-based predictive modeling[J]. *International Journal of Molecular Sciences*, 2022, 23(20): 12272.
- [40] LIU Y, YANG Y, CHEN W D, et al. DeepRTAlign: Toward accurate retention time alignment for large cohort mass spectrometry data analysis[J]. *Nature Communications*, 2023, 14(1): 8188.
- [41] MELNIKOV A D, TSENTALOVICH Y P, YANSHOLE V V. Deep learning for the precise peak detection in high-resolution LC-MS data[J]. *Analytical Chemistry*, 2019, 92(1): 588-592.
- [42] GLOAGUEN Y, KIRWAN J A, BEULE D. Deep learning-assisted peak curation for large-scale LC-MS metabolomics[J]. *Analytical Chemistry*, 2022, 94(12): 4930-4937.
- [43] DATE Y, KIKUCHI J. Application of a deep neural network to metabolomics studies and its performance in determining important variables[J]. *Analytical Chemistry*, 2018, 90(3): 1805-1810.
- [44] FENG Y, CHENG Z J, WEI X, et al. Novel method for rapid identification of *Listeria monocytogenes* based on metabolomics and deep learning[J]. *Food Control*, 2022, 139: 109042.
- [45] TRELOAR N J, FEDOREC A J H, INGALLS B, et al. Deep reinforcement learning for the control of microbial co-cultures in bioreactors[J]. *PLoS Comput Biol*, 2020, 16(4): e1007783.
- [46] MENDIOLA-RODRIGUEZ T A, RICARDEZ-SANDOVAL L A. Robust control for anaerobic digestion systems of *Tequila vinasses* under uncertainty: A deep deterministic policy gradient algorithm[J]. *Digital Chemical Engineering*, 2022, 3: 100023.
- [47] LI D, ZHU Y, MEHMOOD A, et al. Intelligent identification of foodborne pathogenic bacteria by self-transfer deep learning and ensemble prediction based on single-cell Raman spectrum[J]. *Talanta*, 2025, 285: 127268.
- [48] YURDEM B, KUZLU M, GULLU M K, et al. Federated learning: Overview, strategies, applications, tools and future directions[J]. *Heliyon*, 2024, 10(19): e38137.
- [49] KONEČNÝ J, MCMAHAN H B, RAMAGE D, et al. Federated optimization: Distributed machine learning for on-device intelligence[PP/OL]. arXiv preprint arXiv, (2016-10-08)[2025-05-06]. <https://doi.org/10.48550/arXiv.1610.02527>.
- [50] DURRANT A, MARKOVIC M, MATTHEWS D, et al. The role of cross-silo federated learning in facilitating data sharing in the agri-food sector[J]. *Computers and Electronics in Agriculture*, 2022, 193: 106648.
- [51] FENDOR Z, VAN DER VELDEN B H M, WANG X X, et al. Federated learning in food research[J]. *Journal of Agriculture and Food Research*, 2025, 23: 102238.
- [52] KISELEVA A, KOTZINOS D, DE HERT P. Transparency of AI in healthcare as a multilayered system of accountabilities: Between legal

- requirements and technical limitations[J]. *Frontiers in artificial intelligence*, 2022, 5: 879603.
- [53] KELLY C J, KARTHIKESALINGAM A, SULEYMAN M, et al. Key challenges for delivering clinical impact with artificial intelligence[J]. *BMC medicine*, 2019, 17: 1-9.
- [54] MADIEGA T. Artificial intelligence act [EB/OL]. (2021-04-21)[2025-05-06]. <http://data.europa.eu/eli/reg/2024/1689/oj>.
- [55] SRINIVASU P N, SANDHYA N, JHAVERI R H, et al. From blackbox to explainable AI in healthcare: Existing tools and case studies[J]. *Mobile Information Systems*, 2022, 2022(1): 8167821.
- [56] NOHARA Y, MATSUMOTO K, SOEJIMA H, et al. Explanation of machine learning models using shapley additive explanation and application for real data in hospital[J]. *Computer Methods and Programs in Biomedicine*, 2022, 214: 106584.
- [57] ZAFAR M R, KHAN N. Deterministic local interpretable model-agnostic explanations for stable explainability[J]. *Machine Learning and Knowledge Extraction*, 2021, 3(3): 525-541.
- [58] LAATIFI M, DOUZI S, EZZINE H, et al. Explanatory predictive model for COVID-19 severity risk employing machine learning, shapley addition, and LIME[J]. *Scientific Reports*, 2023, 13(1): 5481.
- [59] MOHSENI P, GHORBANI A. Exploring the synergy of artificial intelligence in microbiology: Advancements, challenges, and future prospects[J]. *Computational and Structural Biotechnology Reports*, 2024, 1: 100005.